Journal of the Korean Data & Information Science Society
2021, **32**(3), 585–592

http://dx.doi.org/10.7465/jkdi.2021.32.3.585
한국데이터정보과학회지

서울시 공공자전거 수요예측 모형 비교 연구†

민소아[1] · 정윤서[2]

[1]LG CNS DTI사업부 · [2]고려대학교 통계학과

접수 2021년 4월 30일, 수정 2021년 5월 12일, 게재확정 2021년 5월 17일

요 약

최근 환경 및 교통 문제 현안의 대안으로서 공공자전거 이용 활성화 정책이 양산되고, 그 사용량이 증가하고 있다. 본 논문에서는 서울시에서 제공하는 공공자전거의 일별 대여이력을 바탕으로 공공자전거 수요 예측을 위한 모형들을 비교 분석한다. 대여소별 시계열 데이터에 대한 상관성을 가정한 벡터 자기회귀 모형 (VAR)과 독립성 가정이 요구되지 않는 기계 학습모형인 서포트 벡터 회귀 모형 (SVR), 비독립 데이터에 특화된 딥러닝 기법인 LSTM 모형, 그리고 비유사성 측정방법에 따라 데이터를 군집화하는 시계열 군집 분석 기법을 활용한 SVR 모형과 VAR 모형을 이용하여 자전거 대여 데이터를 모델링하고 수요 예측에 사용하여 그 예측의 정확도를 비교한다.

주요용어: LSTM, 공공자전거 운영 정책, 다변량 시계열 분석, 서포트 벡터 회귀 모형, 시계열 군집 분석.

1. 서론

본 논문에서는 다양한 기법을 활용한 시계열 데이터 모델링을 통해 서울시 공공자전거(일명 '따릉이')의 수요 예측을 위해 여러 가지 모형들을 비교하고자 한다. 이를 위하여 여러 가지 모델들을 이용하여 약 1년치의 일별 자전거 이용량의 데이터를 적합하고, 이 모형을 이용한 예측 오차 (prediction error)를 바탕으로 모델의 성능을 평가 비교하는 것이 이 논문의 목적이다.

분석을 위한 데이터는 다변량의 시계열 데이터로서 공공자전거 데이터는 일별 대여소들간에 상관관계가 있다. 그러므로 우선적으로 다변량 시계열 분석 모형 (vector autoregression)을 고려할 수 있다.

다음으로는 시계열 데이터에서 추출된 일련의 특징을 비교하여 집단간의 비유사성을 측정해 데이터를 군집화하는 방법인 시계열 군집 분석 (Time series clustering)을 활용한다 (Montero와 Vilar, 2014). 시계열 데이터에 대한 군집분석은 많은 응용분야에서 수행될 수 있다. 유사한 방식으로 움직이는 주식을 찾거나 유사한 판매 패턴을 가진 제품을 결정하고, 인구 증가율이 비슷한 국가를 식별하거나 온도가 비슷한 지역을 식별하는 것은 시계열 간의 유사성 분석에 대한 분명한 동기를 부여하는 전형적인 응용분야이다.

다음으로는 수요예측을 위해 서포트 벡터 회귀모형 (support vector regression)을 고려한다 (Drucker 등, 1996). 선형 분류 뿐만 아니라, 커널 방법 (kernel method)이라 불리는 (입력 자료의) 다차원 공간

† 이 논문은 2019년도 과학기술정보통신부의 재원으로 한국연구재단의 지원을 받아 수행된 연구임. (No. 2019R1F1A1040515, No. 2019R1A4A1028134) 고려대학교 정책대학원 데이터 통계학과 민소아의 석사논문에 기초하여 작성함.

[1] (07795) 서울특별시 강서구 마곡중앙 8로 71, LG CNS DT Innovation사업부 금융 Innovation담당, 책임.
[2] 교신저자: (02841) 서울특별시 성북구 안암로 145, 고려대학교 통계학과, 부교수.
E-mail: yoons77@korea.ac.kr

상으로의 매핑기법을 이용하여 비선형 분류도 효율적으로 수행하며, 뛰어난 학습 성능을 보이는 장점이 있다 (Cristianini 와 Taylor, 2000). 특히 오차항에 독립가정이 있지 않기 때문에 시계열 데이터를 적합하는데 적절하다.

마지막 비교 대상으로 채택한 모델은 LSTM (long short-term memory networks)모델이다 (Hochreiter와 Schmidhuber, 1997). LSTM 모델은 특별한 종류의 순환신경망 (recurrent neural networks, RNN)으로서, 순환신경망은 일반적인 인공신경망과 달리 신경망 내부에 기억된 기존 입력에 대한 은닉층 값이 다음 입력 값에 대한 출력시 고려되기 때문에 순차적이거나 시계열적인 정보를 효과적으로 모델링 할 수 있는 특징을 가지고 있다 (Williams 등, 1986). LSTM은 일반적인 순환신경망의 고질적인 가중치 소실 (vanishing gradient) 문제를 방지할 수 있어 시계열 자료 예측에 유용한 것으로 알려져 있고 (Tran 과 Song, 2017), 서로 의존적인 데이터에 특화된 딥러닝 모형이다.

본 논문은 총 4절로 구성되어 있다. 2절에서는 분석 대상 데이터의 수집 및 데이터 전처리와 분석에 사용한 방법에 대하여 서술한다. 3절에서는 실제 자료를 바탕으로 데이터를 분석한 절차 모형의 구체적인 변수 선택과정 및 적합의 결과를 서술하며 최종적으로 각 모형의 예측력을 비교하여 모델의 성능을 평가한다. 마지막 4절에서는 연구의 한계점과 향후 연구 방향에 대하여 기술한다.

2. 데이터 개요 및 분석 방법론 고찰

2.1. 데이터 개요

공공자전거는 대중 교통수단의 보완적인 수단 및 친환경 교통수단으로서 점차 인식 되어가고 있으며, 시민건강의 증진과 체력 향상을 위해 자전거 이용 활성화 및 자전거를 위한 도로시설 확충, 관련 정책 개발이 국가 차원의 중점 과제로 자리잡고 있다. 서울시의 공공자전거 '따릉이' 이용량은 지속적으로 증가하여 2019년 3분기에 635만여건으로 2017년 3분기 181만여건 대비 약 3.5배 증가했다. 언제 어디서나 자전거 이용이 가능한 환경을 조성하여 이용자의 편의 증진과 생활교통 수단으로서의 역할 증대 목적으로 추진하고 있는 서울시 공공자전거 운영 사업의 예산도 14년 약 14억에서 18년 약 188억, 19년 약 320억원으로 급격히 증가하고 있으며, 대여소 추가설치 및 운영관리 등에 사용되고 있다.

서울시 공공자전거는 17년부터 19년까지 3년 연속 서울시 정책 중 시민들의 가장 큰 공감을 이끌어낸 정책이다. 서울시는 19년 8월 기준 2만 5천대에서 20년에는 약 4만대의 자전거 비치를 목표로 하고 있다. 그러나, 이용량이 급증하면서 대여소 생성이 급증하고 있으나, 대여소에 자전거가 없거나 대여소별 거리가 멀다는 불편 사항도 증가하고 있다. 따라서, 시설 투자 계획 등 효율적인 정책수립을 위해서는 정확한 수요 예측이 선행되어야 한다.

본 논문은 2018년 5월부터 2019년 4월까지 1년간의 서울시 공공자전거 대여이력 데이터를 분석 대상으로 한다. 서울시 열린 데이터 광장을 통해 데이터를 수집하였으며, 원시 데이터는 일별 시간대별 자료로서 1년간의 데이터 수집을 위해 총 16개의 파일을 통합하였다. 원시 자료는 자전거번호, 대여일시, 대여소번호, 반납일시, 반납대여소번호, 이용시간 (분) 등 총 11개의 변수로 구성되어 있고, 1년간의 데이터를 통합한 자료의 양은 총 1,170만 여건이다. 정확한 자전거 수요 예측을 위해 자료의 이상치와 자전거 이용 기준에 맞지 않는 대여시간 자료를 제거하는 등 첫번째 전처리를 실시하였다. 즉, 자전거 이용시간이 0분이거나 최대 연속 대여가능 시간인 6시간을 초과하는 자료는 제거하고, 일별 대여소별로 그룹핑하여 분석을 위한 구조로 재집계한다. 그 결과 자료는 총 499,472건으로 2011개 대여소에 대한 365일간의 대여 이력이 생성되었다. 그러나, 대여소별 데이터가 365일 동안 연속적으로 존재하는지 여부를 확인 및 정련한 결과 389개 대여소의 자료에만 데이터의 연속성이 있다. 즉, 1622개 대여소는 기간 내에서 생성과 폐쇄가 발생된 것으로 생각되며, 1년간 연속성이 없는 자료는 분석 데이터로 적절하지

않다고 판단되어 분석 대상에서 제외한다. 이와 같은 과정을 거쳐 총 389개 대여소에 대한 365일 간의 자전거 이용 데이터를 분석에 사용한다.

2.2. 분석 방법론 소개

2.2.1. 시계열 군집 분석 (Time series clustering)

시계열 군집 분석은 거리함수에 의해 시계열 간의 비유사성을 측정하여 군집내에서 비유사성이 최소가 되도록 데이터를 군집화하는 방법이다. 이 방법은 서로 연관이 되어 있는 유전자 분석이나, 여러 지역에서 측정한 날씨 데이터의 분석에도 사용이 된다. 시계열 군집 분석에 대한 자세한 리뷰는 Aghabozorgi 등 (2015)에 주어져 있다. 이를 수행하기 위한 R 패키지 TSclust에는 시계열 군집 분석을 위한 20여개 이상의 거리함수 옵션이 제공되며, 제공되는 거리함수 옵션 중 본 논문에서는 CID (complexity-invariant dissimilarity measure)와 ACF (autocorrelation-based distances)를 이용하여 군집화를 시행하였다. 군집별 수요 예측 모형은 VAR (Vector Auto Regression)모형과 SVR (Support Vector Regression)모형을 사용한다.

2.2.2. 서포트 벡터 회귀 모형 (Support vector regression; SVR)

Support vector를 통해 학습된 데이터에 대한 오차를 최소화하는 기계 학습법인 SVM은 하나의 집단과 다른 집단으로 분류하는 최적의 경계면을 찾아 데이터를 분류한다 (Vapnik, 1996). SVM은 분류 (classification) 또는 회귀 (regression)문제 해결에 이용 가능하며, 문서분류, 영상인식, 문자인식, 시계열 예측 및 분류 등에서 뛰어난 성능을 보여준다.

기존의 학습 알고리즘이 경험적 위험 최소화 원칙 (Empirical risk minimization)을 구현하는 것인데 비해 SVM은 구조적 위험 최소화 원칙 (Structural risk minimization)에 기반하므로 과대적합을 피할 수 있다. SVM에서 회귀영역으로 확장된 서포트 벡터 회귀 (support vector regression, SVR)는 Cortes와 Vapnik(1995)에 의해 제안된 학습기법이다.

2.2.3. LSTM모형 (Long short-term memory networks)

딥러닝 (deep learning) 모형 한 종류인 LSTM은 순환신경망(RNN)이 변형된 모형이다. 순환신경망은 입력에서 출력으로만 진행되는 일반적인 인공신경망과는 다르게 입력과 출력이 순환되는 구조이다. 순환신경망은 일반적인 인공신경망과 달리 신경망 내부에 기억된 기존 입력에 대한 은닉층 값이 다음 입력 값에 대한 출력시 고려되기 때문에 순차적이거나 시계열적인 정보를 효과적으로 모델링 할 수 있는 특징을 가지고 있다. 따라서, 순환신경망의 장점은 이전의 정보를 현재의 문제 해결에 활용할 수 있다는 것이다. 하지만 순환신경망은 과거의 관측 값에 의존하는 구조이기 때문에 기울기가 소실 (vanishing gradient)되거나 기울기가 매우 큰 값 (exploding gradient)을 가지게 되는 문제가 있다. LSTM 모형은 이러한 일반적인 순환신경망의 장기의존성 문제를 해결할 수 있고, 시계열 자료 분석에 유용하다 (Tran과 Song, 2017). 구체적인 예시로는 Lee 등 (2019)은 LSTM을 전력사용량과 그 시간대에 이용하여 최대 전력사용량과 그 시간대를 예측하였고, Lee 와 Oh (2019)는 KOSPI200 선물지수의 일간 그리고 30분간 자료의 분석과 예측에 LSTM 모형을 사용하였다.

3. 공공자전거 수요예측 분석

이 장에서는 세가지 유형의 모형을 적합하고 결과를 기술한다. 우선, 시계열 군집 분석을 활용해 VAR모형과 SVR모형을 적합한다. 특히, SVR모형에서는 시계열 군집 분석을 활용한 모형 뿐만 아니라 군집을 고려하지 않는 모형을 적용해 두 결과에 대한 비교를 포함한다. 마지막으로 딥러닝 기법인 LSTM모형을 적용해 추출된 결과를 분석한다. 세가지 모형 모두 1일부터 361일까지의 데이터를 바탕으로 미래의 세시점을 예측하며, 예측 모형의 평가는 예측 오차 (prediction error)를 바탕으로 성능을 비교하며 오차의 측도로는 RMSE (Root Mean Squared Error)와 MAE (Mean Absolute Error)를 사용한다. 예측의 구체적인 방법으로는, 1일부터 361일까지의 데이터를 바탕으로 한시점 (362일)을 예측하고, 한시점으로 예측된 결과를 두시점의 설명변수로 반영해 두시점 (363일)을 예측하며, 마지막으로 두시점으로 예측된 결과를 다시 세시점의 설명변수로 넣어 세시점 (364일)을 예측한다.

3.1. 시계열 군집을 활용한 다변량 시계열 분석

시계열 분석을 위해 우선적으로 BIC로 선택한 래그수 (lag order)를 사용하여, 포트맨토 (portmanteau) 검정을 통해 잔차(residual)에 계열 상관관계 (serial correlation)가 없는지 확인한다. 일부 대여소를 바탕으로 수행한 결과 래그 (lags)가 7일 때 정상성 (stationarity) 가정에 크게 위배하지 않음을 확인하였으며 (p-value>0.05), 이것은 자전거 이용이 주 (week) 단위 특정 패턴 즉, 평일보다 주말에 자전거 이용량이 증가하는 패턴이 반영된 것으로 판단하여 전체 대여소 모형 적합에 반영한다.

시계열 군집 분석 (Time Series Clustering)의 비유사성을 측정하는 거리함수 중 ACF (Autocorrelation-based Dissimilarity)에 의해 군집화된 데이터를 활용하여 군집별로 각각 VAR모형을 적합한다. 수행한 결과는 Table 3.1과 같으며, Table 3.1에서 보는 바와 같이 MSE 값이 크게 도출된다. 전체 데이터를 하나의 VAR 모형에 적합하는 방법도 시도하였으나 분석에 사용된 변수의 수 즉, 전체 자전거 대여소의 개수가 389개로 차원이 커서 R 패키지에서는 적합에 실패하였다.

Table 3.1 Prediction errors using times series clustering based VAR

prediction	RMSE	MAE
day 362	56.03	35.19
day 363	114.82	58.90
day 364	205.63	97.47

3.2. 시계열 군집을 활용한 서포트 벡터 회귀 분석

시계열 데이터에 대한 서포트 벡터 회귀 모형을 최적화 하기 위해서는 모형에 적합한 커널함수 (kernel function) 결정이 필요하다. 서포트 벡터 회귀 모형 구축시 관측된 자료에 대한 사전 정보가 없을 때는 RBF (radial basis function) 커널함수가 주로 사용된다 (Karatzoglou 등, 2006). 389개 차원을 가진 시계열 데이터에 대한 SVR 모형 적합을 위해 본 논문에서는 비선형 분류를 위해 커널함수 RBF를 사용하고, 추정오차에 대한 패널티 (penalty)를 제어하는 초월모수 (hyper-parameter)인 C, 그리고 훈련데이터 허용 에러율과 관련된 ϵ는 R에서 제공하는 디폴트값을 사용한다. SVR type은 epsilon-SVR과 nu-SVR을 이용한다. SVR 모형은 e1071 패키지의 svm 함수를 이용하였고, 이때에 epsilon-SVR의 경우에는 cost=1, epsilon=0.1이 디폴트 값으로, nu-SVR의 경우에는 cost=1, nu=0.5가 디폴트 값이다. 데이터는 시계열 군집 분석에 의한 데이터와 그룹을 고려하지 않는 전체 데이터를 각각 반영하여 모형 적합 후 세시점에 대한 예측을 순차적으로 수행한다.

또한, 시계열 군집 분석의 CID (complexity-invariant dissimilarity measure)에 의해 데이터를 군집화 하여 덴드로그램 (dendrogram)에 의해 군집된 모습을 육안으로 확인한 후 3개로 데이터를 분리 생성하여 SVR모형에 반영한다. Table 3.2는 CID함수에 의해 3개의 그룹으로 군집화한 데이터를 반영하여 epsilon-SVR과 nu-SVR을 수행한 결과를 비교한 표이다. nu-SVR와 epsilon-SVR의 예측 오차가 비슷함을 알 수 있다.

Table 3.2 Prediction errors using two support vector regression models with clustered data

prediction	RMSE		MAE	
	epsilon SVR	nu-SVR	epsilon SVR	nu-SVR
day 362	14.76	14.61	12.31	12.24
day 363	13.52	13.42	10.92	10.82
day 364	7.10	7.07	5.27	5.23

Table 3.3은 시계열 군집 분석을 하지 않은 전체 데이터로 epsilon-SVR과 nu-SVR을 수행한 결과이다. Table 3.3에서 보듯이 시계열 군집을 고려하지 않은 경우도 시계열 군집기반 수행 결과와 마찬가지로 nu-SVR와 epsilon SVR가 비슷한 예측력을 보여준다.

Table 3.3 Prediction errors using two support vector regression models using all data

prediction	RMSE		MAE	
	epsilon SVR	nu-SVR	epsilon SVR	nu-SVR
day 362	14.75	14.61	12.30	12.24
day 363	13.53	13.48	10.92	10.85
day 364	7.11	7.12	5.29	5.28

Table 3.2와 Table 3.3을 비교해보면 대체적으로 군집을 고려한 경우의 결과가 전체 데이터에 의한 모델링 결과보다 예측력이 좋은 것을 볼 수 있다. 군집화를 하지 않은 데이터의 경우에는 전체 389개의 대여소를 모두 이용하여 SVR 모형을 적합하게 된다. 군집화된 데이터의 경우에는 군집마다 각각 서로 다른 SVR 모형을 적합하여 각 모형에 사용되는 샘플의 수가 많이 줄어들게 된다. 따라서 만일 본 논문에서 고려한 세 개의 군집이 임의로 이루어졌다고 가정한다면, 각 모형의 적합에 이용된 샘플의 수가 389개보다 훨씬 적기 때문에 모형의 예측력이 현저히 감소되어야 하나, 이와는 반대로 군집별로 나누어 적은 샘플들로 예측한 세 개의 모형들의 예측력이 비슷하거나 약간 우세한 것으로 관찰된다. 이와 같은 사실에 근거하여 군집화가 잘 이루어져서 군집내의 변동성이 전체 데이터의 변동성에 비하여 많이 줄어들었고, 이에 따라 예측의 정확도가 올라갔다고 판단할 수 있다. 이는 마치 단순 선형 회귀모형에서 데이터에 군집이 존재하는 경우에는 이를 반영하여 군집별로 다른 기울기를 고려한 모형이 성능이 더 좋아질 수 있다는 사실과 유사하다.

서포트 벡터 회귀모형 수행을 통해 다음과 같은 세 가지의 결과를 알 수 있다. 첫째는 군집을 고려하지 않은 전체 데이터로 수행한 결과보다 오히려 군집화한 데이터로 수행한 경우의 예측력이 다소 좋다. 둘째로는 한시점 예측한 결과보다 두시점, 세시점으로 갈수록 예측력이 더 좋게 나타난다. 앞 시점의 예측 결과를 뒤시점의 설명변수로 넣으면 실제값과의 오차가 점점 더 커질 것로 생각했던 것과 달리, 뒤로 갈수록 예측 시점별 오차가 점점 더 작아지는 것은 의외의 결과이다. 그러나 원시 데이터를 확인한 결과 예측한 날인 362일부터 364일의 실제 공공자전거 대여량이 뒤로 갈수록 점점 더 작았기 때문으로 예측값도 더 작아져서 이에 따라 예측 오차값도 줄어드는 것으로 확인되며, 예측의 성능이 증가하였다고는 볼 수는 없는 결과이다. 마지막으로, 그 차이가 미미한 수준이긴 하나 군집별로 모델링한 결과가 데이터를 나누지 않은 전체 데이터를 기준으로 모델링한 결과보다 예측력이 더 우수하다. 이것은 Time Series

Clustering 수행을 거친 군집별로 최적의 모형을 만들면, 보다 정확한 예측을 할 수 있다는 Montero 와 Vilar (2014)의 주장에 부합하는 결과라고 볼 수 있다.

3.3. 딥러닝 기반 LSTM

LSTM 모형을 수행하기 전 시계열 데이터를 차분하여 시간 종속적인 데이터의 구성 요소를 제거한 자료로 변환과정을 거친다. 다른 신경망 모델과 마찬가지로 입력 자료를 활성화 함수의 범위로 조정한다. R 패키지 keras 를 이용하여 LSTM 모형을 적합하며 모형 정의에는 keras_model_sequential(), layer_lstm(), layer_dense() 함수를 이용하고, 모형의 컴파일에는 compile() 함수를 이용한다. R에서 제공하는 LSTM의 디폴트 활성화함수는 -1부터 1의 범위인 hyperbolic tangent (tanh)함수이다. 본 연구에서는 투입변수 (input variables)는 다변량 시계열변수인 361개, 출력변수 (output variables)는 3개, 배치 (batch)의 크기는 1로, 활성화 함수는 hyperbolic tangent (tanh)와 ReLU 그리고 시그모이드(sigmoid) 함수를 이용한다. MSE (Mean Squared Error)를 손실 함수로, ADAM (Adaptive Monument Estimation)을 최적화 알고리즘으로 사용하고, 각 업데이트에 대한 학습 속도 및 학습 속도의 감소를 지정하였다. 마지막으로 정확성 (accuracy)을 모델 성능을 평가하기 위한 지표로 사용한다. 1일부터 361일까지의 공공자전거 대여량을 바탕으로 향후 3일의 대여량을 예측하고, 이와 같은 작업을 대여소의 개수만큼 즉, 389회 반복 수행한다. 이렇게 수행하여 얻은 LSTM 모형의 수행 결과는 Table 3.4와 같다. RMSE, MAE 값이 앞에서 수행한 두 모형에 비해 현저히 낮게 도출되었음을 확인할 수 있다.

Table 3.4 Prediction errors of the considered models including LSTM. tanh, ReLU, and sigmoid represent the employed activation function in LSTM.

prediction	measure	Model				
		VAR	SVR	LSTM (tanh)	LSTM (ReLU)	LSTM (sigmoid)
day 362	RMSE	56.04	14.61	11.04	13.10	11.87
	MAE	35.19	12.24	7.92	7.88	8.86
day 363	RMSE	114.82	13.42	8.69	8.42	8.72
	MAE	58.90	10.82	6.06	5.56	6.41
day 364	RMSE	205.63	7.072	7.53	6.08	6.43
	MAE	97.47	5.23	5.09	4.07	4.72

Table 3.4에서 보이는 바와 같이 한시점, 두시점 예측에서는 딥러닝 기법인 LSTM 모형이 다른 기법에 비해 뛰어난 성능을 보여준다. 세시점 예측에서는 SVR 모형의 RMSE와 MAE도 비교적 작게 나왔음을 알 수 있다. LSTM에 사용된 여러 활성화함수들을 사용한 결과는 서로 비슷비슷하다.

VAR 모형의 경우는 다른 기법에 비해 오차가 매우 크게 나타났고, 예측 시점이 뒤로 갈수록 더욱 크게 벌어진다. 뒷시점으로 갈수록 오차가 점점 작아지는 SVR 모형과 LSTM 모형과는 다른 형태를 보인다. 따라서, VAR 모형은 서울시 공공자전거 수요 예측을 위한 모형으로는 적절하지 않은 것으로 판단된다. SVR 모형에서는 시계열 군집을 기반으로 최적의 모형을 만들면 전체 데이터로 적합한 모형보다 그 차이가 크지는 않았으나 예측력이 좋게 나올 수 있음을 위에서 확인하였다. 이상의 결과를 종합하면 LSTM, SVR, VAR 모형 순으로 예측력이 좋게 나왔으며, LSTM이 VAR모형보다는 자전거 수요 예측 오차가 현저히 줄어들었으나, SVR과 비교했을때에는 약간의 성능 향상이 있음을 발견하였다. 그 이유는 VAR 모형에서 요구되는 여러가지 가정들 (변수들간의 연관성 구조나 자기회귀 구조)이 실제 사용된 데이터와 괴리가 있어서일 것으로 짐작이 된다. 반면, SVR과 LSTM은 그러한 가정이 없기 때문에 이 두 모형의 예측 성능이 VAR에 비하여 월등한 것으로 이해된다. SVR의 경우 더 세밀한 조율 모수의 튜

닝이 있었다면 현재 LSTM과의 차이가 더 줄어들 것으로 판단되어 두 모형의 성능 비교에 대해서 결론을 내리려면 더 많은 데이터 분석이 필요하다.

4. 한계점 및 추가 연구 방향

389개 차원을 가진 365일간의 서울시 공공자전거 원천 데이터를 바탕으로 시계열 데이터 예측과 관련된 방법론을 적용하고, 일반적인 시계열 분석 기법, 머신 러닝 기법, 그리고 딥러닝 기법을 다양하게 적용하여 예측한 결과를 비교함으로써 실제 정책 수립시 활용 가능성을 보여주었다. 그러나, VAR 모형의 경우 전체 데이터로 모델링 수행이 완료되지 않아 불가피하게 데이터를 나누어 진행해야만 했다. 이에 따라 시계열 군집 분석을 기반으로 군집화한 것 뿐만 아니라 재차 데이터를 분리 수행해야 하는 작업이 부가적으로 수반되었다. 따라서, 전체 데이터로 모델링 및 시계열 군집에 의한 데이터 그 자체로 수행하여 예측하지 못한 한계점이 있다.

가장 좋은 모형으로 판단된 LSTM 모형에서는 R의 단변량 버전을 바탕으로 389개 대여소에 대해 반복 수행을 하였다. 각 대여소별 세 시점에 대한 예측치를 구해 실제값과 비교 계산한 것으로서 전체 대여소에 대해 일괄적으로 모델링 및 예측한 결과가 아니므로 완전성 측면에서는 부족한 한계가 있었다. 향후 다변량 LSTM 모형을 적합하여 본다면 흥미로운 연구가 될 것이다.

References

Aghabozorgi, S., Shirkhorshidi, A. S. and Wah, T. Y. (2015). Time-series clustering - A decade review. *Information Systems*, **53**, 16-38.

Cortes, C. and Vapnik, V. (1995). Support vector networks. *Machine Learning*, **20**, 273-297.

Cristianini, N. and Shawe-Taylor, J. (2000). *An introduction to support vector machines and other kernel-based learning methods*, Cambridge University Press

Drucker, H., Burges, C., Kaufman, L., Smola, A. and Vapnik, V. (1996). *Support vector regression machines*, MIT Press, NIPS96, 155-161.

Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, **9**, 1735-1780.

Karatzoglou, A., Meyer, D. and Hornik, K. (2006). Support vector machine in R. *Journal of Statistical Software*, **15**, 1-28.

Lee, J. H., Kim, J. S., Ahn, Y. H. and Cho, W. S. (2019). Daily forecasting of energy demand using SARIMA and LSTM method to support decision making on V2G. *Journal of the Korean Data & Information Science Society*, **30**, 779-795.

Lee, N. Y. and Oh, K. J. (2019). KOSPI200 futures index prediction using denoising filter and LSTM. *Journal of the Korean Data & Information Science Society*, **30**, 645-654.

Williams, R., Hinton, G. and Rumelhart, D. (1986). Learning representations by back-propagating errors. *Nature*, **323**, 533-536.

Montero, P. and Vilar, J. A. (2014). TSclust: An R package for time series clustering. *Journal of Statistical Software*, **62**, 1-43.

Tran, Q. K. and Song, S. K. (2017). Water level forecasting based on deep learning: A use case of Trinity river-Texas-The United States. *Journal of Korean Institute of Information Scientists and Engineers*, **44**, 607-612.

Vapnik, V. (1996). *The nature of statistical learning theory*, Springer-Verlag, New York.

Journal of the Korean Data & Information Science Society
2021, **32**(3), 585–592

http://dx.doi.org/10.7465/jkdi.2021.32.3.585
한국데이터정보과학회지

Comparative study of prediction models forpublic bicycle demand in Seoul†

Soah Min[1] · Yoonsuh Jung[2]

[1]LG CNS
[2]Department of Statistics, Korea University

Received 30 April 2021, revised 12 May 2021, accepted 17 May 2021

Abstract

Recently, as an alternative to environmental and transportation issues, the policy of activating the use of public bicycles has been mass-produced and the usage has increased. This paper compares and studies the model for predicting the demand of public bicycles based on the daily rental history of public bicycles in Seoul. VAR model which is extended from univariate autoregressive model to multivariate autoregressive model, the SVR model, which does not require independent assumptions, and the LSTM model, which is a deep learning technique specialized in dependent data are compared. In addition, a time series clustering analysis technique that clusters data according to a dissimilarity measure is used in SVR and VAR models. The performance is compared using RMSE and MAE. The predictive power of the LSTM model is the best, and the next is SVR. VAR model shows lowest predictive power compared to the other models.

Keywords: LSTM, public bicycle policy, support vector regression, time series clustering, vector autoregression.

† Jung's work has been partially supported by National Research Foundation of Korea (NRF) grants funded by the Korea government(MIST) 2019R1F1A1040515 and 2019R1A4A1028134. This paper is based on Soah Min's Master thesis.

[1] BE Professional, DTI Finance Innovation Unit, LG CNS, Seoul, 07795, Korea.
[2] Corresponding author: Associate professor, Department of Statistics, Korea University, Seoul 02841, Korea. E-mail: yoons77@korea.ac.kr